LAPORAN UJIAN TENGAH SEMESTER

Nama: Lintang Isa Mardani

NIM: 24031554104

Kelas: 2024B

Mata Kuliah: Graf Sains Data

Tugas Pendahuluan

1. Apa nama database yang digunakan pada tutorial ini?

Nama databasenya adalah neo4j. Ini merupakan default database yang otomatis dibuat saat pertama kali Neo4J diinstal.

2. Sebutkan akses lain (seperti sintaks DDL/DML CYPHER) yang dapat digunakan mengakses database lain dalam 1 instance!

Dalam satu instance Neo4J, kita bisa mengakses database lain dengan beberapa cara:

- Menggunakan parameter database_="nama_database" di Python driver saat memanggil driver.execute_query().
- Menggunakan perintah :USE nama_database jika sedang berada di Neo4J Browser.
- Menggunakan perintah DDL (Data Definition Language) seperti CREATE DATABASE namadb;, DROP DATABASE namadb;, atau SHOW DATABASES; (perintah ini dijalankan di database system).
- Melakukan operasi DML (Data Manipulation Language) seperti MATCH, CREATE, MERGE, DELETE di dalam database yang sudah dipilih.

3. Apa jenis graf pertenanan yang telah dibuat di sini?

Jenis grafnya adalah Directed Graph (Graf Berarah) dengan tipe Property Graph.

- Node (Simpul): Memiliki label Person dengan properti name.
- Relationship (Relasi): Menggunakan tipe KNOWS yang memiliki arah (dari a ke friend). Karena menggunakan MERGE (a)-[:KNOWS]->(friend), relasinya tidak simetris.

Soal UTS 2.1: Wrangling & EDA

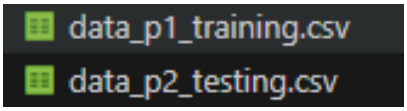
1. Penentuan Periode Waktu dan Filter Data

Berdasarkan periode yang dipilih, data interaksi RetailRocket difilter menjadi dua periode:

- Periode 1 (P1 / Training): 18 Mei 2015 – 31 Mei 2015
- Periode 2 (P2 / Testing): 16 Agustus 2015 – 31 Agustus 2015

2. Proses filter dilakukan menggunakan Python (Pandas) dengan mengonversi Unix timestamp ke format datetime, lalu menyimpannya ke dalam dua file .csv terpisah (data_p1_training.csv dan data_p2_testing.csv).

```
# 3. Filter Periode
p1_mulai = '2015-05-18'
p1_akhir = '2015-05-31 23:59:59'
p2_mulai = '2015-08-16'
p2_akhir = '2015-08-31 23:59:59'
```



3. Query Komposisi Subgraph

Berikut adalah hasil query komposisi simpul (Node) dan relasi (Edge) menggunakan Python API:

- Simpul Visitor: 1.407.580 buah
- Simpul Item: 235.061 buah
- Relasi VIEWED: 2.664.312 buah
- Relasi ADDED_TO_CART: 69.332 buah
- Relasi BOUGHT: 22.457 buah

```
KOMPOSISI SIMPUL (NODES)
Simpul Visitor: 1407580 buah
Simpul Item: 235061 buah
Simpul Person: 4 buah

KOMPOSISI RELASI (EDGES)
Relasi VIEWED: 2664312 buah
Relasi ADDED_TO_CART: 69332 buah
Relasi BOUGHT: 22457 buah
Relasi SIMILAR_TO: 5 buah
Relasi KNOWS: 3 buah
```

Penjelasan CYPHER SQL yang Digunakan:

MATCH (n) RETURN labels(n)[0] AS Jenis_Simpul, count(n) AS Jumlah: Query ini mencari semua simpul (Node), mengambil label utamanya (Visitor atau Item), dan menghitung total masing-masing label.

MATCH ()-[r]->() RETURN type(r) AS Jenis_Relasi, count(r) AS Jumlah: Query ini mencari semua relasi (Relationship), mengambil tipe relasinya, dan menghitung totalnya.

4. Vector Space Modelling (VSM) terhadap Simpul User

VSM terhadap User dibuat dengan menjadikan User sebagai baris dan Item sebagai kolom. Nilai 1 diberikan jika ada interaksi, dan 0 jika tidak.

- Karakteristik: Dimensi Shape yang terbentuk dari sampel data adalah (1444, 114). Artinya, terdapat 1444 User dan 114 Item unik.
- Sparsity: Matriks ini memiliki tingkat sparsity sebesar 99.09%. Hal ini menunjukkan bahwa matriks sangat sparse (jarang) karena mayoritas user hanya berinteraksi dengan sangat sedikit item dari total keseluruhan item yang ada.

```
KARAKTERISTIK VSM USER
Dimensi Shape: (1444, 114)
Artinya: Ada 1444 User (baris) dan 114 Item (kolom).

Contoh 5 baris pertama Matriks:
item  5206    7438    10572   16813   17655   ...  455763  456005  456784  458588  459752
user                                          ...
135        0       0       0       0       0  ...       0       0       0       0       0
774        0       0       0       0       0  ...       0       0       0       0       0
925        0       0       0       0       0  ...       0       0       0       0       0
1674       0       0       0       0       0  ...       0       0       0       0       0
1879       0       0       0       0       0  ...       0       0       0       0       0

[5 rows x 114 columns]

Tingkat Sparsity: 99.09% (Matriks sangat jarang karena mayoritas isinya 0)
```

5. Vector Space Modelling (VSM) terhadap Simpul Item

VSM terhadap Item adalah kebalikannya, di mana Item menjadi baris dan User menjadi kolom.

- Karakteristik: Dimensi Shape yang terbentuk adalah (114, 1444). Artinya, ada 114 Item dan 1444 User.
- Sparsity: Sama seperti VSM User, tingkat sparsity-nya juga 99.09%.

```
KARAKTERISTIK VSM ITEM
Dimensi Shape: (114, 1444)
Artinya: Ada 114 Item (baris) dan 1444 User (kolom).

Contoh 5 baris pertama Matriks:
user   135     774     925     1674    1879    8140    9656    ...  1400572  1400683  1400799  1401134  1401837  1402656  1405774
item                                                           ...
5206       0       0       0       0       0       0       0  ...        0        0        0        0        0        0        0
7438       0       0       0       0       0       0       0  ...        0        0        0        0        0        0        0
10572      0       0       0       0       0       0       0  ...        0        0        0        0        0        0        1
16813      0       0       0       0       0       0       0  ...        0        0        0        0        0        0        0
17655      0       0       0       0       0       0       0  ...        0        0        0        0        0        0        0

[5 rows x 1444 columns]

Tingkat Sparsity: 99.09%
```

6. Analisis Proyeksi VSM (User vs Item)

Secara umum, proyeksi VSM User lebih efektif jika tujuannya adalah melakukan rekomendasi berbasis User-Based Collaborative Filtering (mencari user yang mirip untuk merekomendasikan item). Namun, pada dataset RetailRocket, jumlah User (1,4 juta) jauh lebih banyak dibandingkan jumlah Item (235 ribu). Oleh karena itu, secara efisiensi komputasi, proyeksi VSM Item lebih unggul karena matriks yang dihitung lebih kecil, sehingga proses perhitungan similarity antar item akan lebih cepat.

7. Perhitungan Similarity dan Penyimpanan ke Graf

Menghitung Cosine Similarity berdasarkan VSM User. Dipilih secara acak User ID 135 sebagai acuan.

(a) CYPHER SQL untuk 5 Similarity Tertinggi:

Table | Raw

	User_Acuan	User_Mirip	Skor_Similarity
1	135	675082	1.0
2	135	655027	1.0
3	135	47622	1.0
4	135	1397566	1.0
5	135	583567	1.0

(b) Penyimpanan ke Graf: Nilai similarity tersebut disimpan kembali ke dalam graf Neo4J dalam bentuk relasi baru bernama SIMILAR_TO dengan properti score.



8. Kondisi Sebelum dan Sesudah Perhitungan Similarity

- Sebelum: Graf hanya terdiri dari simpul Visitor dan Item yang dihubungkan oleh relasi interaksi (VIEWED, ADDED_TO_CART, BOUGHT).



- Sesudah: Pada graf ditambahkan relasi baru antar Visitor yaitu SIMILAR_TO yang menghubungkan User Acuan dengan User terdekat beserta bobot skornya.



Soal UTS 2.2: Analytics

1. Rekomendasi KNN (K-Nearest Neighbors)

(a) Pemilihan User Acak (Reproducible): Proses pemilihan user menggunakan fungsi random.seed(42) agar hasil dapat direproduksi, lalu memilih ID User secara acak. Terpilih User ID: 1111394.

(b) 3 Item yang diiklankan (k=5): Dengan mencari 5 user terdekat menggunakan Cosine Similarity, didapatkan 3 item yang direkomendasikan untuk diiklankan kepada User 1111394:

- Item ID: 198798 (Skor Relevansi: 2.0000)
- Item ID: 29100 (Skor Relevansi: 0.0000)
- Item ID: 76196 (Skor Relevansi: 0.0000)

```
5 User KNN terdekat:
user
1124889    1.0
1368107    1.0
1406941    0.0
1401134    0.0
1580       0.0
Name: 1111394, dtype: float64

3 ITEM YANG DIREKOMENDASIKAN (IKLAN)
1. Item ID: 198798 (Skor Relevansi: 2.0000)
2. Item ID: 29100 (Skor Relevansi: 0.0000)
3. Item ID: 76196 (Skor Relevansi: 0.0000)
```

2. Evaluasi Rekomendasi (Hit@5 & NDCG@5)

Berdasarkan rekomendasi di atas, dilakukan pengecekan terhadap histori interaksi User 1111394 pada data testing (P2). Hasilnya, User tersebut tidak memiliki histori interaksi dengan ketiga item rekomendasi tersebut.

(a) Hit@5: 0 (Tidak ada satupun dari 3 item rekomendasi yang relevan/dilihat oleh user di periode testing).

(b) NDCG@5: 0.0000 (Karena tidak ada item yang relevan, maka nilai Discounted Cumulative Gain (DCG) adalah 0, sehingga nilai normalisasinya juga 0).

```
Item Rekomendasi: [198798, 29100, 76196]
Item yang benar-benar dilihat User 1111394 di P2: []

=> Hit@5: 0
=> NDCG@5: 0.0000
```